Détection d'anomalies dans un réseau d'aéroports avec des GNN

Nour Ben Mansour, Mohamed ali Damergi and Léo Morin

Université Claude Bernard Lyon 1, France

Abstract. We study link and node anomaly detection in a network of 3,363 airports and 13,547 edges. Using synthetic corruptions, we compare graph neural networks with simple baselines. Adamic–Adar achieves the best link AUC, while GAE/VGAE improve average precision for rare anomalies. DOMINANT mainly detects geographic errors, whereas GAT identifies corrupted population values. These results highlight the importance of feature preprocessing and the limitations of synthetic evaluation. Code: `https://github.com/LeoMor1/projet-GNN_2026-2027`.

Keywords: Graph neural networks, graph autoencoder, link anomaly detection

1 Introduction

Le graphe étudié relie 3363 aéroports par 13547 liaisons non orientées ; chaque nœud a une latitude, une longitude, la population de sa ville, un nom de ville et un pays. Une partie de ces informations est fausse, et certains liens aussi. Nous comparons ce qu'un modèle prédit à ce qui est observé et regardons où les deux divergent le plus, selon trois volets : les liens (GAE, VGAE), puis les nœuds (GCN, GAT) pour les pays, positions et populations erronés. Code : `https://github.com/LeoMor1/projet-GNN_2026-2027`.

2 État de l'art

Liens. La prédiction de liens repose sur la similarité des voisinages : voisins communs, Jaccard et Adamic–Adar [1,5], qui pondère les voisins communs selon leur degré. Ces méthodes n'utilisent ni attributs ni apprentissage. Le GAE et le VGAE [3] combinent un encodeur GCN [4] et un décodeur fondé sur le produit scalaire des embeddings, le VGAE ajoutant une distribution latente et un terme KL. Pour les graphes attribués, DOMINANT [2] reconstruit la structure et les attributs (revue : [6]). Nos baselines incluent Jaccard, Adamic–Adar et la distance géographique.

Nœuds. La détection d'anomalies identifie les nœuds dont les attributs ou les relations s'écartent du comportement attendu [6]. DOMINANT [2] utilise l'erreur de reconstruction des attributs et de la structure, tandis que le GAT [7] apprend à pondérer les voisins par attention. GraphRfi [8] détecte les fraudes via l'erreur de prédiction, principe que nous appliquons à la population des aéroports. Les baselines sont la moyenne globale et la moyenne des voisins.

3 Anomalies de liens : GAE / VGAE

3.1 Protocole et modèle

Sans étiquettes de liens erronés, nous injectons $r|E|$ arêtes entre des paires non reliées, pour $r \in \{1, 5, 10, 20\}\,\%$, avant le découpage entraînement/validation/test (70/10/20 %). Les modèles sont entraînés à reconstruire la structure ; les liens injectés peuvent donc aussi apparaître à l'entraînement. Les attributs d'entrée sont la latitude, la longitude et la population, standardisées. Le GAE utilise deux couches GCN ($3 \to 64 \to 32$) ; le VGAE partage la première couche puis estime la moyenne et la variance latentes, avec une pénalité KL. Les deux sont entraînés par Adam (taux 0,01, 200 époques) avec cinq graines. Le score d'anomalie est $1 - p_{ij}$, où p_{ij} est la probabilité reconstruite. Nous rapportons l'AUC et la précision moyenne (AP).

3.2 Résultats

Table 1. Liens injectés : moyenne sur 5 graines, écart-type entre parenthèses (0,952(4) = 0,952 ± 0,004). Gras : meilleur. AP aléatoire : 0,010 à 0,167 ($r/(1+r)$).

	$r = 1\,\%$		$r = 5\,\%$		$r = 10\,\%$		$r = 20\,\%$	
Méthode	AUC	AP	AUC	AP	AUC	AP	AUC	AP
Distance (km)	0,914(12)	0,080(7)	0,916(5)	0,298(9)	0,915(3)	0,452(6)	0,916(3)	0,613(7)
Jaccard	0,949(6)	0,098(3)	0,947(2)	0,349(3)	0,946(2)	0,516(4)	0,946(1)	0,679(2)
Adamic–Adar	**0,952**(4)	0,098(3)	**0,951**(2)	0,351(3)	**0,951**(1)	0,519(3)	**0,950**(1)	**0,683**(2)
GAE	0,945(7)	0,190(25)	0,936(4)	0,429(19)	0,929(4)	**0,552**(8)	0,917(3)	0,650(7)
VGAE	0,943(9)	**0,193**(14)	0,933(3)	**0,434**(15)	0,927(4)	0,551(10)	0,916(2)	0,654(5)

Adamic–Adar a le meilleur AUC à tous les taux (0,95 contre 0,917 à 0,945) sans apprentissage (tableau 1). Les autoencodeurs ne gardent l'avantage en AP que si les anomalies sont rares. GAE et VGAE diffèrent de moins de 0,005, comme l'écart-type : le VGAE n'apporte rien de démontré.

Sur le graphe d'origine (graine 42), les dix premiers liens relient surtout un grand aéroport à une destination éloignée (Paris–Cayenne), probablement réels. Une vraie erreur : le VGAE classe cinquième Ottawa–Iqaluit, or le nœud « Ottawa » est placé en (−27,9; 144,6), en Australie, alors que ses voisins sont nord-américains : le lien est correct, les attributs du nœud sont faux.

Table 2. Ablation du GAE ($r = 10\,\%$, 5 graines).

	Complet	1 couche GCN	Sans standardisation	Sans attributs	$\dim Z = 8$
AUC	0,929(4)	0,846(10)	0,500(0)	0,812(3)	0,930(3)
AP	0,552(8)	0,365(14)	0,091(0)	0,202(4)	0,558(16)

3.3 Évaluation et ablation

Une couche ou l'absence d'attributs dégradent le GAE (tableau 2) ; sans standardisation, la population ($\sim 10^7$) sature probablement le sigmoïde.

4 Anomalies de nœuds : GCN

4.1 Protocole et modèle

Nous cherchons des *nœuds* anormaux : des aéroports dont les attributs ou les liaisons s'écartent de ceux de leurs voisins. Sans étiquette « nœud faux », nous entraînons DOMINANT [2] par reconstruction, sans étiquette, sur le graphe complet : un nœud est d'autant plus suspect qu'il est mal reconstruit.

Les entrées sont $F = 7$ attributs standardisés : la position sur la sphère unité (x, y, z), $\log(1 + \text{pop})$ avec un indicateur de population manquante (valeur par défaut 10 000), et $\log(1 + d)$ pour les distances moyenne et minimale, en km, aux voisins du graphe. L'encodeur a trois couches GCN ($7 \to 64 \to 32 \to 16$) avec ReLU et dropout 0,2, le décodeur d'attributs deux couches ($16 \to 32 \to 7$), le décodeur structurel une couche ($16 \to 16$) puis $\sigma(\tilde{Z}\tilde{Z}^\top)$. La perte est $\mathcal{L}_{\text{struct}} + \mathcal{L}_{\text{attr}}$: entropie croisée sur toutes les paires et erreur quadratique sur X. Le score d'un nœud somme ses deux erreurs de reconstruction,

$$s_i = \tfrac{1}{F}\|x_i - \hat{x}_i\|^2 + \tfrac{1}{N}\textstyle\sum_j \ell_w\big(a_{ij}, \sigma(\tilde{z}_i^\top \tilde{z}_j)\big),$$

recentré par la médiane et divisé par le MAD. Adam (0,005, 500 époques), 5 entraînements indépendants dont les scores sont moyennés.

4.2 Résultats

L'erreur d'attributs passe de 0,9997 à 0,38–0,39 en 500 époques, la structure de 1,10 – 1,31 à 0,79–0,80 ; les cinq entraînements convergent à moins de 0,01

Neuf des dix nœuds sont mal géolocalisés (tableau 3) : leurs coordonnées contredisent leur nom et leurs voisins (Hasvik en Norvège placé en Nouvelle-Zélande, St Thomas aux Caraïbes placé en Australie, Wewak en Papouasie placé au Canada). Les features les plus mal reconstruites sont positionnelles (r_{if} de 27 à 55), la population reste proche de la moyenne. Frankfurt fait exception : coordonnées correctes, mais population par défaut 10 000 bien en dessous de sa connectivité (log pop $\times$27,2), une erreur de donnée, pas de position. Les liens ne sont pas en cause : pour les dix nœuds, le lien existant le moins plausible garde une probabilité $\geq 0{,}71$. Pour les nœuds mal placés, les liens absents les

Table 3. Dix nœuds les mieux classés (moyenne de 5 entraînements). Position : (lat , lon) du fichier, feature la plus mal reconstruite, rapport r_{if} à l'erreur moyenne.

Rang	Nœud	Position	Voisins	Feature
1	St Thomas Island	(−24,1; 134,4)	Caraïbes	$d_{\min}$ ×36,3
2	Hasvik	(−43,9; 169,1)	Norvège	z ×53,4
3	Cagliari	(−32,3; 125,5)	Italie	z ×35,6
4	Ottawa	(−27,9; 144,6)	Canada	z ×42,5
5	Jersey	(−35,4; 145,7)	R.-U., France	z ×44,2
6	Wewak	(49,0; −122,8)	Papouasie-N.-G.	$d_{\min}$ ×27,3
7	Frankfurt	(50,0; 8,6)	monde entier	log pop ×27,2
8	Sara	(58,2; −135,3)	Vanuatu	$d_{\min}$ ×28,5
9	Budapest	(−24,9; 152,3)	Europe	z ×40,7
10	Casablanca	(−28,9; 153,1)	Maroc	x ×54,7

plus attendus (p > 0,99) vont vers les hubs de leur région réelle (Atlanta, Dallas, Denver pour Ottawa) : l'embedding retrouve la région d'un nœud à partir de ses voisins malgré ses coordonnées. Ottawa relie aussi cette analyse à la section 3 : le VGAE y classait haut le lien Ottawa–Iqaluit alors que ce sont les attributs du nœud qui sont faux.

4.3 Évaluation et ablation

Nous évaluons par injection : pour $r \in \{1, 5, 10, 20\}\,\%$, sur $\lceil rN \rceil$ nœuds tirés au hasard, puis AUC et précision moyenne (AP) sur la séparation corrompus/reste, moyennées sur 5 entraînements. L'AP aléatoire vaut r.

	$r = 1\,\%$		$r = 5\,\%$		$r = 10\,\%$		$r = 20\,\%$	
Modèle	AUC	AP	AUC	AP	AUC	AP	AUC	AP
Complet	**0,954**(12)	**0,197**(41)	**0,933**(6)	**0,433**(25)	**0,912**(5)	**0,537**(17)	**0,866**(7)	**0,612**(16)
Ablation	0,484(33)	0,011(1)	0,485(24)	0,049(4)	0,489(19)	0,097(7)	0,489(9)	0,194(6)

Table 4. Nœuds injectés : moyenne sur 5 entraînements, l'écart-type entre parenthèses porte sur le dernier chiffre (0,954(12) = 0,954 ± 0,012). Une AP aléatoire vaut r.

La performance décroît avec r : les nœuds corrompus participant à l'entraînement, le modèle apprend partiellement à les reconstruire (l'erreur d'attributs finale monte de 0,39 à 0,50 entre $r = 0$ et 20 %). L'AP est la métrique pertinente : avec des anomalies rares, l'AUC est dominée par la masse des vrais négatifs.

Sans prétraitement (lat/lon/pop brutes), la méthode tombe au niveau du hasard à tous les taux : AUC ≈ 0,49, AP ≈ r. Dominée par la population brute (erreurs quadratiques $\sim 10^{14}$), la perte stagne à 3×10^{11} et le modèle n'apprend aucune régularité positionnelle, son classement ne reflète que la taille des villes. La détection repose donc sur la conception des attributs et non sur l'architecture seule.

4.4 Protocole et modèle

Sans étiquette « nœud faux », nous entraînons DOMINANT [2] sur le graphe complet : un nœud est d'autant plus suspect qu'il est mal reconstruit. Les entrées sont $F = 7$ attributs standardisés : position sur la sphère unité (x, y, z), $\log(1 + \text{pop})$ avec indicateur de population manquante (défaut 10 000), et $\log(1+d)$ pour les distances moyenne et minimale aux voisins. L'encodeur a trois couches GCN ($7 \to 64 \to 32 \to 16$), le décodeur d'attributs deux couches ($16 \to 32 \to 7$), le décodeur structurel une couche puis $\sigma(\tilde{Z}\tilde{Z}^\top)$. Le score d'un nœud somme ses deux erreurs de reconstruction, recentré médiane/MAD. Adam (0,005, 500 époques), 5 entraînements dont les scores sont moyennés.

4.5 Résultats

L'erreur d'attributs passe de 0,9997 à 0,38 et celle de structure de 1,10 à 0,80, avec une convergence stable des cinq entraînements ($< 0{,}01$). Neuf des dix nœuds les plus mal reconstruits sont mal géolocalisés (Hasvik placé en Nouvelle-Zélande, St Thomas en Australie, Wewak au Canada), avec des erreurs positionnelles élevées ($r_{if} = 27$ à 55). Frankfurt fait exception : sa position est correcte, mais sa population par défaut $(10,000)$ est sous-estimée. Les liens restent plausibles ($p \geq 0{,}71$) et les liens absents les plus probables ($p > 0{,}99$) pointent vers les hubs de la région réelle, montrant que l'embedding retrouve la région malgré des coordonnées erronées. Enfin, Ottawa relie cette analyse à la section 3 : le VGAE classe haut le lien Ottawa–Iqaluit, alors que l'anomalie vient des attributs du nœud.

4.6 Évaluation et ablation

Par injection de $r \in \{1, 5, 10, 20\}\,\%$ de nœuds corrompus, le modèle atteint une AUC de 0,95 ($r = 1\,\%$) à 0,87 ($r = 20\,\%$) et une AP de 0,20 à 0,61 (moyenne sur 5 entraînements). La performance décroît avec r car les nœuds corrompus participent à l'entraînement, l'erreur d'attributs passant de 0,39 à 0,50 entre $r = 0$ et $20\,\%$. Sans prétraitement (lat/lon/pop brutes), la méthode tombe au niveau du hasard (AUC $\approx 0{,}49$, AP $\approx r$), la perte étant dominée par la population brute : la détection repose sur la conception des attributs, pas sur l'architecture seule.

5 Anomalies de nœuds : GAT

5.1 Protocole et modèle

Comme GraphRfi [8], nous prédisons la population d'un aéroport à partir de sa position et de ses liaisons : un nœud est suspect si sa population observée s'écarte de la prédiction. La cible est $y_i = \log(1 + \text{pop}_i)$, standardisée et exclue des entrées, qui comprennent lat, lon et $\log(1 + \text{deg})$, également standardisées.

Une couche GAT [7] agrège les voisins selon des coefficients d'attention appris, avec K têtes concaténées :

$$\alpha_{ij} = \mathrm{softmax}_j\left(\mathrm{LeakyReLU}(a^\top [Wh_i \,\|\, Wh_j])\right), \qquad h'_i = \Big\|_{k=1}^{K} \sum_j \alpha_{ij}^k W^k h_j.$$

Comme $\sum_j \alpha_{ij} = 1$, le degré est ajouté en entrée pour conserver l'information sur le nombre de voisins. Le modèle comporte deux couches ($3 \to 64$, $K = 4$, puis $256 \to 64$, $K = 1$), des activations ELU, un dropout de 0,2 et une couche linéaire. Il est entraîné par MSE sur 80,

Pour l'évaluation, nous multiplions ou divisons la population de rN nœuds par un facteur de 10 à 100, en les conservant dans l'entraînement, puis calculons l'AUC et l'AP sur les 20,

5.2 Résultats

Table 5. Populations injectées, nœuds test, moyenne sur 5 graines (écart-type sur le dernier chiffre entre parenthèses). Une AP aléatoire vaut environ r.

	$r = 1\,\%$		$r = 5\,\%$		$r = 10\,\%$		$r = 20\,\%$	
Méthode	AUC	AP	AUC	AP	AUC	AP	AUC	AP
Moyenne globale	0,881(77)	0,297(133)	0,828(45)	0,373(77)	0,807(43)	0,499(89)	0,823(19)	0,665(20)
Moyenne des voisins	0,792(77)	0,169(48)	0,791(61)	0,253(100)	0,777(34)	0,343(64)	0,762(14)	0,460(45)
GAT	**0,911**(32)	**0,524**(115)	**0,896**(22)	**0,575**(80)	**0,900**(26)	**0,698**(75)	**0,899**(16)	**0,790**(17)

Le GAT bat les deux baselines à tous les taux (tableau 5), avec une AUC stable vers 0,90 : ne voyant pas la population en entrée, il ne peut pas apprendre à recopier les valeurs faussées. En prédiction, le GAT atteint $R^2 = 0{,}37(3)$ sur les nœuds test, et l'ablation le fait baisser à chaque fois : 0,29 sans le degré, 0,32 sans les liens (degré gardé), 0,31 avec une couche et 0,34 avec une tête. Le degré compte le plus, mais les voisins aident aussi.

Sur le graphe d'origine (graine 42), le top 20 mêle des mégapoles sous-estimées (Delhi, Karachi) et des erreurs de données : Francfort (234 liaisons), Calcutta et deux autres villes à exactement 10 000 habitants, valeur par défaut de 1673 nœuds sur 3363, et Hamilton (Nouvelle-Zélande) avec 902 habitants, probablement ceux de Hamilton aux Bermudes.

6 Comparaison et conclusion

Les anomalies visées diffèrent, donc les AUC ne sont pas directement comparables, mais deux constats se recoupent. La qualité des entrées décide de tout : sans standardisation ou prétraitement, le GAE et DOMINANT tombent au niveau du hasard (AUC 0,5 et 0,49). Et sur le graphe réel, les modèles retrouvent de vraies erreurs : Ottawa placé en Australie, Francfort à 10 000 habitants (valeur par défaut de 1673 nœuds), Hamilton (Nouvelle-Zélande) avec la population de Hamilton aux Bermudes.

Table 6. Les trois approches (injection de $r = 1$ à 20 % d'anomalies ; AUC et AP du $r = 1\,\%$ au $r = 20\,\%$).

Modèle	Anomalie ciblée	Score	AUC	AP
GAE	liens ajoutés	$1 - p_{ij}$	0,945 → 0,917	0,19 → 0,65
GCN (DOMINANT)	attributs, position	reconstruction	0,95 → 0,87	0,20 → 0,61
GAT	population	$\lvert\hat{y}_i - y_i\rvert$	0,911 → 0,899	0,52 → 0,79

Limites : anomalies injectées aléatoires donc faciles (Adamic–Adar bat les autoencodeurs en AUC), tops issus d'une seule graine. À faire : vérifier les tops sur OpenFlights, combiner les trois scores.

Références

1. Adamic, L.A., Adar, E. : Friends and neighbors on the Web. Social Networks 25(3), 211–230 (2003)
2. Ding, K., Li, J., Bhanushali, R., Liu, H. : Deep anomaly detection on attributed networks. In : Proceedings of the SIAM International Conference on Data Mining (SDM). pp. 594–602 (2019)
3. Kipf, T.N., Welling, M. : Variational graph auto-encoders. In : NIPS Workshop on Bayesian Deep Learning (2016)
4. Kipf, T.N., Welling, M. : Semi-supervised classification with graph convolutional networks. In : International Conference on Learning Representations (ICLR) (2017)
5. Liben-Nowell, D., Kleinberg, J. : The link-prediction problem for social networks. Journal of the American Society for Information Science and Technology 58(7), 1019–1031 (2007)
6. Ma, X., Wu, J., Xue, S., Yang, J., Zhou, C., Sheng, Q.Z., Xiong, H., Akoglu, L. : A comprehensive survey on graph anomaly detection with deep learning. IEEE Transactions on Knowledge and Data Engineering 35(12), 12012–12038 (2023)
7. Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., Bengio, Y. : Graph attention networks. In : International Conference on Learning Representations (ICLR) (2018)
8. Zhang, S., Yin, H., Chen, T., Hung, Q.V.N., Huang, Z., Cui, L. : GCN-based user representation learning for unifying robust recommendation and fraudster detection. In : Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. pp. 689–698 (2020)