Détection d'anomalies dans un réseau d'aéroports avec des GNN

Nour Ben Mansour and Léo Morin

Université Claude Bernard Lyon 1, France

Abstract. We look for erroneous links in an airport network (3363 nodes, 13547 edges) with graph autoencoders. Since the data has no link labels, we inject random false edges at rates between 1% and 20% and rank every edge by $1 - p_{ij}$, where p_{ij} is the decoder's reconstruction probability. A GAE and a VGAE reach an AUC of 0.92–0.94, with no clear difference between them. Adamic–Adar, which needs no training, has a higher AUC at every rate; the autoencoders only keep an edge in average precision when anomalies are rare. On the original graph, the top-ranked edges are mostly long but plausible routes, and one of them points to a node with wrong coordinates. Code: `https://github.com/LeoMor1/projet-GNN_2026-2027`.

Keywords: Graph neural networks, graph autoencoder, link anomaly detection

1 Introduction

Le graphe étudié relie 3363 aéroports par 13547 liaisons non orientées. Chaque nœud a une latitude, une longitude, la population de sa ville, un nom de ville et un pays. Une partie de ces informations est fausse, et certains liens aussi. L'idée est de comparer ce qu'un modèle prédit avec ce qui est observé et de regarder où les deux divergent le plus. Le travail est réparti en trois volets sur le même graphe : les liens (GAE, VGAE), puis les nœuds (GCN, GAT).

Pour les liens, la question est la suivante : un autoencodeur de graphe repère-t-il les liens aberrants mieux qu'une heuristique sans apprentissage, et le VGAE apporte-t-il quelque chose par rapport au GAE ? Le code est disponible à l'adresse `https://github.com/LeoMor1/projet-GNN_2026-2027`.

Étudiants 2 et 3 : question posée sur les nœuds (pays, population), données utilisées (3–4 lignes)

2 État de l'art

Liens. Pour juger un lien, on peut comparer les voisinages de ses extrémités : voisins communs, Jaccard, ou Adamic–Adar [1], qui pondère chaque voisin commun par $1/\log(\deg)$. Ces scores restent des références en prédiction de liens [6] et n'utilisent ni attributs ni apprentissage. Le GAE et le VGAE [4] associent un encodeur GCN [5] à un décodeur $p_{ij} = \sigma(z_i^\top z_j)$; le VGAE rend z_i aléatoire et ajoute un terme KL. SEAL [8] apprend sur le sous-graphe autour de chaque paire. Pour les graphes attribués, DOMINANT [2] reconstruit structure et attributs avec un autoencodeur GCN (revue : [7]). Nos baselines pour les liens sont Jaccard, Adamic–Adar et la distance entre aéroports, comparées au GAE et au VGAE.

Étudiants 2 et 3 : état de l'art nœuds (GCN, GAT, baselines de comparaison), 5–6 lignes

3 Anomalies de liens (étudiant 1)

3.1 Protocole et modèles

Faute d'étiquette « lien faux », nous ajoutons au graphe $r\,|E|$ liens entre des paires non reliées tirées uniformément, $r \in \{1, 5, 10, 20\}\,\%$, *avant* le découpage des liens (`RandomLinkSplit`, 10 % validation, 20 % test). Les modèles sont entraînés par reconstruction, sans étiquette : les liens injectés sont dans le graphe d'entraînement. L'encodeur ne voit que les liens d'entraînement (70 %, injectés compris), et chaque lien du graphe contaminé reçoit le score $s_{ij} = 1 - \sigma(z_i^\top z_j)$ (moyenne μ pour le VGAE). Pour les baselines, le score est l'opposé de l'indice (Jaccard, Adamic–Adar) ou la distance en km.

Les entrées sont lat, lon et population, standardisées. Le GAE a deux couches GCN ($3 \to 64 \to 32$) séparées par une ReLU, et la perte est l'entropie croisée sur les liens d'entraînement et des paires négatives tirées au hasard. Le VGAE a une première couche GCN identique, puis deux couches GCN en parallèle pour μ et $\log\sigma$; sa perte vaut $\mathcal{L}_{\text{rec}} + \frac{1}{N}\text{KL}$ (N nœuds). Adam (taux 0,01, 200 époques) sous PyTorch Geometric [3], graines $42, 123, 456, 789, 2026$. Nous reportons l'AUC et la précision moyenne (AP) ; la précision@10 est trop instable (écart-type jusqu'à 0,25).

3.2 Résultats

Adamic–Adar a le meilleur AUC à tous les taux (0,95 contre 0,917 à 0,945), sans apprentissage ni attribut (tableau 1). Les autoencodeurs gardent l'avantage en AP quand les anomalies sont rares (0,19 contre 0,10 à $r = 1\,\%$), puis il s'inverse à $r = 20\,\%$ (0,68 contre 0,65). La distance seule donne déjà 0,915 : des paires tirées au hasard sont presque toujours éloignées.

Table 1. Liens injectés : moyenne sur 5 graines, l'écart-type est entre parenthèses (dernier chiffre : 0,952(4) = 0,952 ± 0,004). Meilleure valeur en gras. Une AP aléatoire vaut $r/(1+r)$, soit 0,010, 0,048, 0,091 et 0,167.

	$r = 1\,\%$		$r = 5\,\%$		$r = 10\,\%$		$r = 20\,\%$	
Méthode	AUC	AP	AUC	AP	AUC	AP	AUC	AP
Distance (km)	0,914(12)	0,080(7)	0,916(5)	0,298(9)	0,915(3)	0,452(6)	0,916(3)	0,613(7)
Jaccard	0,949(6)	0,098(3)	0,947(2)	0,349(3)	0,946(2)	0,516(4)	0,946(1)	0,679(2)
Adamic–Adar	**0,952**(4)	0,098(3)	**0,951**(2)	0,351(3)	**0,951**(1)	0,519(3)	**0,950**(1)	**0,683**(2)
GAE	0,945(7)	0,190(25)	0,936(4)	0,429(19)	0,929(4)	**0,552**(8)	0,917(3)	0,650(7)
VGAE	0,943(9)	**0,193**(14)	0,933(3)	**0,434**(15)	0,927(4)	0,551(10)	0,916(2)	0,654(5)

Table 2. Ablation du GAE ($r = 10\,\%$, 5 graines, écart-type entre parenthèses). Référence : 2 couches, attributs standardisés, $\dim Z = 32$.

Variante	AUC	AP
GAE complet	0,929(4)	0,552(8)
1 couche GCN	0,846(10)	0,365(14)
Sans standardisation	0,500(0)	0,091(0)
Sans attributs ($X = \mathbf{1}$)	0,812(3)	0,202(4)
$\dim Z = 8$ (au lieu de 32)	0,930(3)	0,558(16)

GAE et VGAE sont à moins de 0,005 l'un de l'autre, comme l'écart-type ; au test de Student apparié, $p > 0{,}2$ dans cinq cas sur huit et $p \approx 0{,}03$–$0{,}05$ dans les trois autres. Rien ne montre que le VGAE améliore le GAE, nous gardons le plus simple.

Sur le graphe d'origine (graine 42), quatre des dix liens les mieux classés sont communs aux deux modèles ; la plupart relient un grand aéroport à une destination éloignée (Paris–Cayenne, Londres–La Barbade) (atypiques, mais probablement réels). Un cas est une vraie erreur : le VGAE classe cinquième Ottawa–Iqaluit, or le nœud « Ottawa » a pour coordonnées (−27,9; 144,6) et pour pays l'Australie, alors que ses 26 voisins sont presque tous canadiens ou américains. Le lien est correct, ce sont les attributs du nœud qui sont faux.

3.3 Ablation du GAE

Avec une seule couche GCN, l'AUC passe de 0,93 à 0,85 (tableau 2). Sans standardisation il vaut exactement 0,5 et l'AP est celle du hasard (0,091) : la population, de l'ordre de 10^7, fait probablement saturer le sigmoïde et tous les scores sont égaux. Sans attributs, l'AUC reste à 0,81 mais l'AP tombe à 0,20. Une dimension latente de 8 donne le même résultat que 32, qui n'est donc pas nécessaire.

Limites : les liens injectés sont tirés au hasard et donc faciles à reconnaître ; un AUC de 0,93 ici ne dit pas que les vraies erreurs seront trouvées. Le top-10 vient d'une seule graine.

4 Anomalies de nœuds : GCN (étudiant 2)

Étudiant 2 : GCN
protocole, méthode, tableau de résultats (AUC/AP ou RMSE), ablation

5 Anomalies de nœuds : GAT (étudiant 3)

Étudiant 3 : GAT
méthode, tableau de résultats (AUC/AP ou RMSE), ablation

6 Comparaison et conclusion

Tous : comparaison finale des modèles (GAE, GCN, GAT), limites, conclusion

Références

1. Adamic, L.A., Adar, E. : Friends and neighbors on the Web. Social Networks 25(3), 211–230 (2003)
2. Ding, K., Li, J., Bhanushali, R., Liu, H. : Deep anomaly detection on attributed networks. In : Proceedings of the SIAM International Conference on Data Mining (SDM). pp. 594–602 (2019)
3. Fey, M., Lenssen, J.E. : Fast graph representation learning with PyTorch Geometric. In : ICLR Workshop on Representation Learning on Graphs and Manifolds (2019)
4. Kipf, T.N., Welling, M. : Variational graph auto-encoders. In : NIPS Workshop on Bayesian Deep Learning (2016)
5. Kipf, T.N., Welling, M. : Semi-supervised classification with graph convolutional networks. In : International Conference on Learning Representations (ICLR) (2017)
6. Liben-Nowell, D., Kleinberg, J. : The link-prediction problem for social networks. Journal of the American Society for Information Science and Technology 58(7), 1019–1031 (2007)
7. Ma, X., Wu, J., Xue, S., Yang, J., Zhou, C., Sheng, Q.Z., Xiong, H., Akoglu, L. : A comprehensive survey on graph anomaly detection with deep learning. IEEE Transactions on Knowledge and Data Engineering 35(12), 12012–12038 (2023)
8. Zhang, M., Chen, Y. : Link prediction based on graph neural networks. In : Advances in Neural Information Processing Systems (NeurIPS). vol. 31 (2018)